

# Dezagregacja danych przedziałowych

Michał Ramsza

M. Ramsza, Warsaw School of Economics  
Department of Mathematics and Mathematical Economics


Why R? 2017

# Plan prezentacji

- Problem
- Algorytm matematyczny
- Implementacja w R
- Przykłady

# Problem (1)

- Mamy dane przedziałowe.
- Chcemy zdezagregować dane na drobniejsze przedziały.



Tego typu zadanie jest często rozwiązywane w zakresie szeregów czasowych ale nie dla danych przedziałowych.

# Problem (2)

- Dana jest funkcja  $y : \mathbb{R} \rightarrow \mathbb{R}$ .
- Dana jest siatka  $\mathcal{A} = (a_0, a_1, \dots, a_N)$ , gdzie  $N \in \mathbb{N}$  zawierająca  $N + 1$  elementów.
- Dane jest  $N$  wartości  $y_n$ ,  $n = 1, \dots, N$ .
- Dana jest nadsiatka  $\mathcal{A}' = (a'_0, a'_1, \dots, a'_K)$ , gdzie
  - $K \in \mathbb{N}$  i  $K > N$
  - dla dowolnego  $n = 0, \dots, N$  zachodzi  $a_n \in \mathcal{A}'$
  - $a'_0 = a_0$  i  $a'_K = a_N$ .

Zadanie polega na znalezieniu “optymalnych” wartości  $y'_k$ ,  $k = 1, \dots, K$ .

# Algorytm matematyczny (1)

- Związek wartości  $y_n$  z funkcją  $y$  i siatką  $\mathcal{A}$  jest zadany operatorem agregacji  $\phi$  w następujący sposób

$$y_n = \phi(y, a_{n-1}, a_n).$$

- Typowy przykład takiego agregatora to suma

$$y_n = \int_{a_{n-1}}^{a_n} y(\tau) d\tau.$$

- Nowe, nieznane wartości  $y'_k$  są zadane tym samym operatorem agregacji

$$y'_k = \phi(y, a'_{k-1}, a'_k).$$

# Algorytm matematyczny (2)

- Operator agregacji  $\phi$  i zależności na siatkach definiują funkcję wiążącą  $\xi$  zadającą zależność

$$y_n = \xi(\{y'_k\}_{k \in K_n}),$$

gdzie  $K_n$  jest zbiorem indeksów postaci

$$K_n = \{k : a_{n-1} \leq a'_k \leq a_n\}.$$

- Przykładowo, dla agregatora będącego sumą zachodzi

$$y_n = \int_{a_{n-1}}^{a_n} y(\tau) d\tau = \sum_{j=1, \dots, \ell_n} \int_{a'_{k_{j-1}}}^{a'_{k_j}} y(\tau) d\tau = \sum_{j=1, \dots, \ell_n} y'_j,$$

gdzie  $\{k_j\}_j = K_n$ . Zatem  $\xi$  jest sumą.

# Algorytm matematyczny (3)

- Dodatkowo do warunków spójności dodany jest selektor  $\mathcal{S}$ . Ściśle, selektor jest funkcją  $\mathcal{S} : \mathbb{R}^K \rightarrow \mathbb{R}$  określoną na wartościach  $y'_k$ .
- Przykładowy selektor może być np. średnią zmianą

$$\mathcal{S}(y'_0, \dots, y'_K) = \sum_{k=1}^{k=K} (y'_k - y'_{k-1})^2.$$

# Algorytm matematyczny (4)

Zadanie uzyskania nowych wartości  $y'_k$  sprowadza się do rozwiązania zadania optymalizacji postaci

$$\min_{y'_k} \mathcal{S}(y'_1, \dots, y'_K)$$

z warunkami ograniczającym postaci

$$y_n = \xi(\{y'_k\}_{k \in K_n}), \quad n = 1, \dots, N$$

oraz ewentualnymi dodatkowymi ograniczeniami (równości lub nierówności) dodanymi przez analityka.



# Implementacja w R

- Model obiektowy S3
- Obiekt `gridData`.
- Typowe metody usługowe typu `print`, `barplot` itd.
- Podstawowa metoda to `resample` obliczającą wartości  $y'_k$ .
- Podstawowe narzędzie to pakiet `alabama` (Ravi Varadhan) implementujący algorytm Augmented Lagrangian Adaptive Barrier Minimization Algorithm

<https://cran.r-project.org/web/packages/alabama/index.html>.

# Great. Let's see the code ...